



PROJET - ETAT DE L'ART

Convex optimization

2025 - 2026

**N Diaye BALL, Melvyn POMMIER, Romain REN et Jacq
VENGADESAN**

7 juin 2026

Table des matières

0	Situer ISTA et FISTA	2
0.1	Le cadre commun : minimiser une somme $f + g$	2
0.2	Descente par coordonnées (<i>coordinate descent</i>)	2
0.3	ADMM (<i>Alternating Direction Method of Multipliers</i>)	3
0.4	Newton proximal (<i>proximal / semismooth Newton</i>)	4
0.5	Synthèse comparative	5

0 Situer ISTA et FISTA

ISTA et FISTA ne sont qu'un point dans un paysage plus large de méthodes capables de résoudre le problème composite

$$\min_{x \in \mathbb{R}^p} F(x) = \underbrace{\frac{1}{2} \|Ax - y\|_2^2}_{f(x) \text{ (lisse)}} + \underbrace{\lambda \|x\|_1}_{g(x) \text{ (non lisse)}}.$$

Le critère d'évaluation du **sujet B** demande explicitement de *comparer les alternatives* : c'est l'objet de cette section. On retient quatre familles concurrentes des méthodes de gradient proximal, la **descente par coordonnées**, l'**ADMM**, le **Newton proximal**, et l'on confronte chacune à ISTA/FISTA selon trois axes que l'on juge décisifs en pratique : la *vitesse de convergence* (en nombre d'itérations), le *coût d'une itération*, et la *structure de problème* pour laquelle la méthode est la mieux adaptée.

0.1 Le cadre commun : minimiser une somme $f + g$

Toutes ces méthodes attaquent le même objet : une somme d'une partie lisse f (de gradient L -lipschitzien, $L = \|A^\top A\|_2$) et d'une partie convexe non lisse g . Ce qui les distingue, c'est la *manière* dont elles exploitent cette structure :

- ISTA/FISTA *séparent* f et g : un pas de gradient sur f , puis l'opérateur proximal de g (le seuillage doux). C'est l'approche *full-gradient* : chaque itération met à jour tout le vecteur x .
- La descente par coordonnées exploite la *séparabilité* de $g = \lambda \|\cdot\|_1 = \sum_j \lambda |x_j|$ pour ne mettre à jour qu'une coordonnée à la fois.
- L'ADMM *dédoublé* les variables (une copie pour f , une pour g) et les recoud via un multiplicateur.
- Le Newton proximal exploite en plus la *courbure* de f (le hessien $A^\top A$), là où ISTA/FISTA n'utilisent que le gradient.

On reconnaît ISTA/FISTA comme le membre le plus « élémentaire » de cette famille : ordre 1, séparation minimale, pas de structure supplémentaire exploitée. Cette sobriété est à la fois leur force (généralité, simplicité, coût par itération faible) et leur limite (convergence sous-linéaire).

0.2 Descente par coordonnées (*coordinate descent*)

Principe. Plutôt que de bouger toutes les composantes de x ensemble, on les met à jour une par une : on fixe toutes les coordonnées sauf la j -ième et on minimise F exactement selon x_j . Pour le LASSO, ce sous-problème à une variable admet une *solution close* — précisément un seuillage doux sur le résidu partiel :

$$x_j \leftarrow \text{soft_threshold}\left(\frac{1}{\|a_j\|_2^2} a_j^\top (y - Ax + a_j x_j), \frac{\lambda}{\|a_j\|_2^2}\right),$$

où a_j est la j -ième colonne de A . On balaie les coordonnées cycliquement (ou aléatoirement) jusqu'à stabilisation.

Vitesse. Pour le LASSO, la descente par coordonnées converge à un taux *asymptotiquement linéaire*, c.-à-d. $F(x_k) - F^* = O(\rho^k)$ avec $\rho < 1$ une fois identifié le support de la solution, bien mieux que le $O(1/k)$ d'ISTA et le $O(1/k^2)$ de FISTA dans ce régime final. C'est d'ailleurs la méthode au cœur de `glmnet`, l'implémentation de référence du LASSO en statistique, et elle est en pratique souvent la plus rapide sur ce type de problème.

Coût par itération. Une mise à jour de coordonnée est très bon marché ($O(n)$ pour le produit $a_j^\top r$ si l'on maintient le résidu $r = y - Ax$ de manière incrémentale). Un balayage complet des p coordonnées coûte $O(np)$, comparable à une itération d'ISTA (dominée par les produits Ax et $A^\top(\cdot)$). L'avantage décisif est l'*identification automatique du support* : les coordonnées nulles le restent, et les balayages ne « travaillent » que sur les variables actives.

Quand la préférer. Lorsque la pénalité est *séparable* (comme $\|\cdot\|_1$) et que les colonnes de A sont peu corrélées. C'est le choix par défaut en grande dimension statistique ($p \gg n$) avec solution très parcimonieuse. En revanche, la méthode est intrinsèquement *séquentielle* (chaque coordonnée dépend des précédentes), donc difficile à paralléliser, et elle perd son avantage quand g n'est pas séparable.

0.3 ADMM (*Alternating Direction Method of Multipliers*)

Principe. On reformule le problème en **dédoublant** la variable : on introduit une copie z et la contrainte $x = z$,

$$\min_{x,z} f(x) + g(z) \quad \text{s.c.} \quad x = z,$$

puis on minimise le *lagrangien augmenté* $L_\rho(x, z, u) = f(x) + g(z) + \frac{\rho}{2}\|x - z + u\|_2^2$ en alternant trois pas :

$$\begin{aligned} x_{k+1} &\leftarrow_x f(x) + \frac{\rho}{2}\|x - z_k + u_k\|_2^2 && \text{(résolution d'un système linéaire),} \\ z_{k+1} &\leftarrow_{g/\rho} (x_{k+1} + u_k) && \text{(seuillage doux),} \\ u_{k+1} &\leftarrow u_k + x_{k+1} - z_{k+1} && \text{(montée de gradient duale).} \end{aligned}$$

La beauté du découplage : f et g ne sont jamais traités ensemble. Le pas en z est exactement le seuillage doux déjà implémenté pour ISTA.

Vitesse. En pratique, l'ADMM atteint une précision modérée en *nettement moins d'itérations* qu'ISTA — souvent quelques dizaines suffisent. Théoriquement, sa vitesse est $O(1/k)$ pour des objectifs convexes généraux, et linéaire sous des hypothèses fortes ; elle dépend toutefois de manière sensible du paramètre de pénalité ρ , dont le réglage est délicat et conditionne fortement la performance observée.

Coût par itération. C'est le point faible : le pas en x exige de résoudre un système linéaire $(A^\top A + \rho I)x = b$. Si A est fixe, on factorise $A^\top A + \rho I$ *une seule fois* (Cholesky, $O(p^3)$) et chaque itération ne coûte plus que deux substitutions $O(p^2)$, l'ADMM devient alors très compétitif. Mais si ρ change (réglage adaptatif) ou si A est trop grande pour être factorisée, le pas en x redevient coûteux. Autre nuance notable : contrairement à ISTA/FISTA et à la descente par coordonnées, les itérés d'ADMM ne sont *pas exactement parcimonieux* avant convergence (seul le bloc z l'est).

Quand le préférer. Quand le problème se *décompose* naturellement (régularisations multiples, contraintes, problèmes distribués sur plusieurs machines), ou quand la factorisation de $A^\top A + \rho I$ peut être amortie sur de nombreuses itérations. L'ADMM brille par sa *modularité* : on peut remplacer g par n'importe quelle fonction dont on sait calculer le prox, sans changer le reste de l'algorithme.

0.4 Newton proximal (*proximal / semismooth Newton*)

Principe. ISTA majore f par un modèle quadratique *isotrope* $\frac{1}{2t}\|x - x_k\|^2$ (une « boule »). Le Newton proximal remplace ce modèle par la *vraie courbure* : il utilise le hessien $H = \nabla^2 f = A^\top A$ et résout, à chaque pas, un sous-problème de la forme

$$x_{k+1} = x - \nabla f(x_k)^\top (x - x_k) + \frac{1}{2}(x - x_k)^\top H(x - x_k) + g(x),$$

soit un LASSO local, résolu approximativement par un solveur interne (souvent de la descente par coordonnées sur le sous-problème). On peut aussi le voir comme une méthode de Newton semi-lisse appliquée à la condition d'optimalité $0 \in \partial F(x^*)$.

Vitesse. C'est le régime le plus rapide *près de l'optimum* : convergence *superlinéaire*, voire *quadratique* localement ($\|x_{k+1} - x^*\| = O(\|x_k - x^*\|^2)$). Là où FISTA demande des centaines d'itérations pour gagner les derniers chiffres de précision, le Newton proximal les obtient en une poignée de pas une fois entré dans le bassin de convergence.

Coût par itération. Très élevé et c'est tout l'enjeu : chaque itération exige une information de second ordre (le hessien ou son action) et la résolution d'un sous-problème interne, donc des itérations « lourdes ». Le pari n'est gagnant que si le faible nombre d'itérations externes compense leur coût unitaire ce qui suppose en général une *phase d'amorçage* par une méthode d'ordre 1 (typiquement FISTA) pour s'approcher de l'optimum avant de basculer sur Newton.

Quand le préférer. Quand on vise une *haute précision* sur un problème de taille modérée, ou quand f est bien conditionnée et que le hessien est exploitable (structure, parcimonie). À l'inverse, en très grande dimension où même former $A^\top A$ est prohibitif, les méthodes d'ordre 1 restent incontournables.

0.5 Synthèse comparative

Le tableau 1 récapitule les compromis. Aucune méthode ne domine partout : le bon choix dépend de la *précision* visée, de la *taille* du problème et de la *structure* exploitable.

Méthode	Ordre	Vitesse	Coût / itération	Terrain de prédilection
ISTA	1	$O(1/k)$	faible ($Ax, A^\top r$)	socle simple, général
FISTA	1	$O(1/k^2)$	faible (idem ISTA)	précision moyenne, par défaut
Coord. descent	1	linéaire (asympt.)	très faible (1 coord.)	g séparable, $p \gg n$
ADMM	1	$O(1/k)$, ρ -dépend.	moyen (système lin.)	décomposable, distribué
Prox. Newton	2	superlin. / quadr.	élevé (hessien + interne)	haute précision, taille modérée

TABLE 1 – Comparaison des principales méthodes pour le LASSO. « Ordre » désigne l'ordre de l'information dérivée utilisée. Les vitesses indiquées sont les taux usuels sur ce problème (le régime linéaire de la descente par coordonnées et le régime quadratique de Newton sont *locaux*, c.-à-d. atteints près de l'optimum).

Discussion des compromis. Trois arbitrages structurent ce paysage.

- **Vitesse vs. coût par itération.** Plus une méthode converge en peu d'itérations (Newton, ADMM), plus ces itérations sont chères. ISTA/FISTA font le pari inverse : des itérations très bon marché, quitte à en faire beaucoup. En grande dimension, ce pari est souvent le bon.
- **Généralité vs. exploitation de structure.** ISTA/FISTA ne demandent que ∇f et le prox de g — d'où leur généralité. La descente par coordonnées exige la séparabilité de g ; le Newton proximal exige une courbure exploitable ; l'ADMM exige une décomposition commode. Ces hypothèses, quand elles tiennent, paient.
- **Mémoire et robustesse.** ISTA/FISTA et la descente par coordonnées ont une empreinte mémoire minimale (quelques vecteurs). L'ADMM stocke une variable duale et, idéalement, une factorisation. Le Newton proximal stocke et manipule de l'information de second ordre, le plus gourmand. Côté robustesse, ISTA est le plus prévisible ; FISTA introduit des oscillations non monotones (cf. section 0 et la figure de convergence du notebook) que des variantes *restart* corrigent ; l'ADMM est sensible à ρ ; Newton dépend d'un bon amorçage.

Position d'ISTA/FISTA. En définitive, FISTA occupe un point d'équilibre remarquable : sans hypothèse de structure au-delà de la séparation $f + g$, sans paramètre délicat à régler, avec un coût par itération minimal, il atteint le *meilleur taux possible pour une méthode du premier ordre* ($O(1/k^2)$, optimal au sens de Nesterov). C'est ce qui en fait le « cheval de bataille » par défaut, et la brique de base à partir de laquelle les autres méthodes se construisent ou se comparent d'où sa place centrale dans ce projet, les autres approches servant de points de repère pour en mesurer les forces et les limites.