

PROJET — RAPPORT

Methodes de gradient proximal

ISTA & FISTA pour l'optimisation convexe non lisse

Convex optimization 2025–2026

N'Diaye BALL, Melvyn POMMIER, Romain REN, Jacq VENGADESAN

June 7, 2026

Contents

1	Introduction et motivation	2
1.1	Du cours a une question laissee ouverte	2
1.2	La technique etudiee : les methodes de gradient proximal	2
1.3	Fil conducteur et application illustrative	2
1.4	Organisation du rapport	2
2	Rappels et cadre theorique	3
2.1	Probleme d'optimisation	3
2.2	Convexite	3
2.3	La propriete fondamentale, et ses limites	3
2.4	Programmation lineaire et quadratique	4
3	Le probleme : minimisation convexe composite	4
3.1	Un probleme inverse sous-determine	4
3.2	Formulation : le LASSO	4
3.3	Le probleme est convexe	5
3.4	Pourquoi les methodes du cours echouent	5
4	Outils theoriques : sous-differentiel et operateur proximal	6
4.1	Le sous-differentiel	6
4.2	Condition d'optimalite	6
4.3	L'operateur proximal	6
4.4	Derivation du seuillage doux	6
4.5	Non-expansivite	6
5	ISTA : l'algorithme de gradient proximal	6
5.1	Idee : separer la partie lisse et la partie non lisse	6
5.2	Construction par majoration-minimisation	6
5.3	L'algorithme	6
5.4	Convergence en $O(1/k)$	6
6	FISTA : acceleration par momentum	6
6.1	Du gradient proximal au momentum de Nesterov	6
6.2	L'algorithme	6
6.3	Convergence en $O(1/k^2)$	6
6.4	Non-monotonie et variantes a restart	6
7	Etat de l'art : situer ISTA et FISTA	6
7.1	Le cadre commun : minimiser une somme $f + g$	6
7.2	Descente par coordonnees	7
7.3	ADMM (Alternating Direction Method of Multipliers)	7
7.4	Newton proximal	8
7.5	Synthese comparative	8
8	Application : separation de sources audio	9
9	Experiences numeriques	9
10	Conclusion	9

1 Introduction et motivation

1.1 Du cours a une question lisee ouverte

Le cours d'optimisation convexe etablit un resultat fondamental : pour une fonction convexe sur un ensemble convexe, *tout minimum local est un minimum global*. Cette propriete — que nous appellerons la « propriete-or » — est ce qui rend les problemes convexes « faciles » a optimiser : il n'existe pas de creux sous-optimal dans lequel un algorithme pourrait rester piege.

Le cours a ensuite presente deux familles de methodes de resolution :

- pour un objectif **lisse** (differentiable), les methodes fondees sur le gradient (descente de gradient, methode de Newton) ;
- pour un objectif **lineaire**, l'algorithme du simplexe.

Ces deux familles couvrent une large part des problemes, mais elles partagent une hypothese implicite forte : la descente de gradient et la methode de Newton exigent que la fonction objectif soit *differentiable*, tandis que le simplexe ne traite que le cas *lineaire*. Une question reste donc ouverte, et c'est precisement celle qu'explore ce projet :

*Comment resoudre un probleme convexe lorsque la fonction objectif est convexe mais **ni lisse**, **ni lineaire** ?*

Ce cas de figure est loin d'etre marginal : il apparait des que l'on ajoute a un objectif lisse un terme de regularisation non differentiable, situation omnipresente en traitement du signal, en statistique et en apprentissage automatique.

1.2 La technique etudiee : les methodes de gradient proximal

Pour repondre a cette question, nous etudions une famille de methodes de premier ordre adaptees au cas non lisse : les **methodes de gradient proximal**, et en particulier l'algorithme **ISTA** (*Iterative Shrinkage-Thresholding Algorithm*) et son acceleration **FISTA** (*Fast ISTA*). Conformement au sujet B, le cœur de ce rapport est l'*etude de cette technique de resolution* : sa construction, ses garanties de convergence, et sa comparaison avec les alternatives existantes.

Il importe de souligner d'emblee qu'ISTA et FISTA *ne sont pas des algorithmes d'apprentissage automatique* : ce sont des algorithmes d'optimisation convexe, au meme titre que le gradient conjuge ou les methodes de point interieur cites dans l'enonce du sujet B. Le fait qu'ils soient frequemment employes en apprentissage ne change rien a leur nature : ils resolvent un probleme d'optimisation, point.

1.3 Fil conducteur et application illustrative

Pour ancrer l'etude dans un probleme concret, nous utilisons comme fil rouge le probleme du **LASSO** (regression lineaire avec penalisation L_1), qui est l'instance canonique d'un objectif convexe composite « lisse + non lisse ». En fin de rapport, nous illustrons l'interet pratique de la methode sur une **application a la separation de sources audio** (section 8) ; cette application reste toutefois une *illustration* et non le sujet : elle rend le probleme tangible et fournit une evaluation quantitative, mais l'analyse demeure centree sur l'optimisation.

1.4 Organisation du rapport

Le rapport s'organise en trois temps. La premiere partie pose le cadre : rappels du cours mobilises (section 2) puis formulation precise du probleme composite et preuve de sa convexite (section 3). La deuxieme partie constitue le cœur theorique : les outils de l'optimisation non lisse, dont l'operateur proximal (section 4), puis les algorithmes ISTA (section 5) et FISTA (section 6) avec

leurs preuves de convergence. La troisième partie met la méthode en perspective : état de l'art comparatif (section 7), application audio (section 8) et expériences numériques (section 9). La section 10 conclut.

2 Rappels et cadre théorique

Cette section rassemble les notions du cours mobilisées dans la suite. Elle ne vise pas l'exhaustivité mais fixe le vocabulaire, les notations et les propriétés sur lesquelles reposent les sections suivantes.

2.1 Problème d'optimisation

Un problème d'optimisation consiste à minimiser (ou maximiser) une fonction objectif $f : A \rightarrow \mathbb{R}$ sur un ensemble admissible A :

$$\min_{x \in A} f(x).$$

Un élément $x \in A$ est une *solution admissible* ; une solution qui réalise le minimum est une *solution optimale*, notée x^* . Lorsque l'ensemble admissible est décrit par des contraintes d'inégalité, on écrit

$$\min_{x \in \mathbb{R}^n} f(x) \quad \text{sous contraintes} \quad c_i(x) \leq b_i, \quad i = 1, \dots, m.$$

2.2 Convexité

Définition 1 (Ensemble convexe). Un ensemble $A \subseteq \mathbb{R}^n$ est *convexe* si, pour tout couple de points de A , le segment qui les joint est entièrement contenu dans A :

$$\forall x, y \in A, \forall \lambda \in [0, 1] : \quad \lambda x + (1 - \lambda)y \in A.$$

Définition 2 (Fonction convexe). Une fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}$ est *convexe* si

$$\forall x, y \in \mathbb{R}^n, \forall \lambda \in [0, 1] : \quad f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y).$$

Géométriquement, tout segment reliant deux points du graphe se situe au-dessus (ou sur) le graphe. Lorsque l'inégalité est *stricte* pour $x \neq y$ et $\lambda \in]0, 1[$, la fonction est dite *strictement convexe*.

Deux propriétés de stabilité, établies en travaux dirigés, seront utilisées pour montrer que notre problème est convexe :

Proposition 1 (Stabilité de la convexité).

1. Un demi-espace $\{x \in \mathbb{R}^n : a^\top x \leq b\}$ est un ensemble convexe ; une intersection d'ensembles convexes est convexe.
2. Une somme de fonctions convexes est convexe ; le produit d'une fonction convexe par un scalaire positif est convexe.

2.3 La propriété fondamentale, et ses limites

Théorème 1 (Propriété-or). *Tout minimum local d'une fonction convexe est un minimum global.*

C'est cette propriété qui justifie l'intérêt des problèmes convexes : un algorithme qui converge vers un minimum local converge en réalité vers l'optimum global. Une précision s'impose toutefois, car elle conditionne la lecture de nos résultats expérimentaux.

Remarque 1 (Convexite et unicite). La convexite garantit l'unicite de la *valeur optimale* F^* , mais **pas** celle du *minimiseur* x^* . L'ensemble des minimiseurs peut etre reduit a un point, mais aussi former tout un segment — le cours en donne d'ailleurs un exemple en programmation lineaire, ou l'ensemble des solutions optimales est un segment entier. L'unicite du minimiseur requiert une hypothese plus forte, la *stricte* convexite. Comme nous le verrons (section 3), le LASSO n'est pas strictement convexe en general ; on ne pourra donc affirmer que la convergence se fait vers une *meme valeur* F^* , et non necessairement vers un *meme point* x^* .

2.4 Programmation lineaire et quadratique

Le cours a etudie en detail la *programmation lineaire*, cas particulier ou objectif et contraintes sont lineaires, resolue par l'algorithme du simplexe. Notre probleme generalise ce cadre dans une direction differente : l'objectif y sera *quadratique* (donc convexe mais non lineaire) et augmente d'un terme de regularisation *non differentiable*. Ni le simplexe ni la descente de gradient classique ne s'y appliquent directement, ce qui motive l'introduction des outils de la section 4.

3 Le probleme : minimisation convexe composite

3.1 Un probleme inverse sous-determine

Placons-nous dans une situation typique du traitement du signal. On observe un vecteur de mesures $y \in \mathbb{R}^n$, relie a un signal inconnu $x \in \mathbb{R}^p$ par une matrice connue $A \in \mathbb{R}^{n \times p}$:

$$y = Ax + \varepsilon,$$

ou ε represente un bruit. Le point determinant est que l'on dispose de *moins de mesures que d'inconnues* ($p > n$) : le systeme est *sous-determine* et admet une infinite de solutions compatibles avec y . Sans information supplementaire, le probleme est mal pose.

L'information que l'on ajoute est une hypothese de **parcimonie** (*sparsity*) : le vrai signal x ne possede que peu de composantes non nulles. Cette hypothese est realiste — de nombreux signaux naturels admettent une representation creuse dans une base adaptee — et suffit a rendre le probleme bien pose.

3.2 Formulation : le LASSO

Pour retrouver x , on minimise un objectif en deux termes, l'un mesurant la fidelite aux donnees, l'autre favorisant la parcimonie :

$$\min_{x \in \mathbb{R}^p} F(x) = \underbrace{\frac{1}{2} \|Ax - y\|_2^2}_{f(x) \text{ (lisse)}} + \lambda \underbrace{\|x\|_1}_{g(x) \text{ (non lisse)}} \quad (1)$$

ou $\|x\|_1 = \sum_{i=1}^p |x_i|$ et $\lambda > 0$ regle le compromis entre les deux termes. Ce probleme est connu sous le nom de **LASSO** (*Least Absolute Shrinkage and Selection Operator*). On notera dans toute la suite

$$f(x) = \frac{1}{2} \|Ax - y\|_2^2, \quad g(x) = \lambda \|x\|_1, \quad F = f + g.$$

Le terme f est differentiable, de gradient

$$\nabla f(x) = A^\top (Ax - y), \quad (2)$$

qui est *lipschitzien* de constante $L = \|A^\top A\|_2$ (la plus grande valeur propre de $A^\top A$). Cette constante jouera un role central dans le choix du pas des algorithmes (sections 5 et 6).

3.3 Le probleme est convexe

Verifions que (1) entre bien dans le cadre du cours.

Proposition 2. *La fonction objectif $F = f + g$ est convexe sur $\mathbb{R}^p$, et l'ensemble admissible $\mathbb{R}^p$ est convexe. Le probleme (1) est donc un probleme d'optimisation convexe.*

Proof. On procede terme a terme.

1. *f est convexe.* La fonction $f(x) = \frac{1}{2} \|Ax - y\|_2^2$ est quadratique, de matrice hessienne $\nabla^2 f(x) = A^\top A$. Pour tout $u \in \mathbb{R}^p$, $u^\top A^\top A u = \|Au\|_2^2 \geq 0$, donc $A^\top A$ est semi-definie positive : f est convexe.
2. *g est convexe.* La norme $\|\cdot\|_1$ est une norme, donc convexe (inegalite triangulaire et homogeneite) ; multipliee par $\lambda > 0$, elle reste convexe (proposition 1).
3. *F est convexe.* Comme somme de deux fonctions convexes, F est convexe (proposition 1).
4. *L'ensemble admissible.* Il s'agit de $\mathbb{R}^p$ tout entier, qui est trivialement convexe.

La propriete-or (theoreme 1) s'applique donc : tout minimum local de (1) est global. □

Remarque 2 (Pas de stricte convexite en general). Conformement a la remarque 1, F n'est pas strictement convexe des que $p > n$. En effet, f n'est strictement convexe que si $A^\top A$ est *definie* positive, c'est-a-dire si A est injective ; or, avec plus de colonnes que de lignes ($p > n$), A possede un noyau non trivial. Quant a $g = \lambda \|\cdot\|_1$, elle est convexe mais pas strictement. On ne peut donc pas garantir l'unicite du minimiseur x^* : les algorithmes des sections suivantes convergeront vers une *memme valeur optimale* F^* , sans que le point atteint soit necessairement unique.

3.4 Pourquoi les methodes du cours echouent

Le terme $g(x) = \lambda \|x\|_1$ fait intervenir des valeurs absolues $|x_i|$. Or la fonction $t \mapsto |t|$ presente un *point anguleux* en 0 : sa derivee vaut -1 a gauche et $+1$ a droite, et **n'existe pas** en 0. Cette simple observation a des consequences directes :

- la **descente de gradient** requiert ∇F , qui n'est pas defini la ou des composantes de x s'annulent — c'est-a-dire precisement la ou se trouve la solution recherchee, puisqu'elle est creuse ;
- la **methode de Newton** exige en outre la hessienne de F , encore moins disponible ;
- le **simplexe** ne traite que les objectifs lineaires, alors que le notre est quadratique.

Il nous faut donc un outil capable de gerer ce point anguleux sans recourir a la differentiability. Cet outil est l'*operateur proximal*, introduit a la section suivante.

4 Outils theoriques : sous-differentiel et operateur proximal

4.1 Le sous-differentiel

4.2 Condition d'optimalite

4.3 L'operateur proximal

4.4 Derivation du seuillage doux

4.5 Non-expansivite

5 ISTA : l'algorithme de gradient proximal

5.1 Idee : separer la partie lisse et la partie non lisse

5.2 Construction par majoration-minimisation

5.3 L'algorithme

5.4 Convergence en $O(1/k)$

6 FISTA : acceleration par momentum

6.1 Du gradient proximal au momentum de Nesterov

6.2 L'algorithme

6.3 Convergence en $O(1/k^2)$

6.4 Non-monotonie et variantes a restart

7 Etat de l'art : situer ISTA et FISTA

ISTA et FISTA ne sont qu'un point dans un paysage plus large de methodes capables de résoudre le probleme composite (1). Le critere d'évaluation du sujet B demande explicitement de comparer les alternatives : c'est l'objet de cette section. On retient quatre familles — les methodes de gradient proximal, la descente par coordonnees, l'ADMM et le Newton proximal — et on confronte chacune a ISTA/FISTA selon trois axes juges decisifs en pratique : la vitesse de convergence (en nombre d'iterations), le cout d'une iteration, et la structure de probleme pour laquelle la methode est la mieux adaptee.

7.1 Le cadre commun : minimiser une somme $f + g$

Toutes ces methodes attaquent le meme objet : une somme d'une partie lisse f (de gradient L -lipschitzien, $L = \|A^\top A\|_2$) et d'une partie convexe non lisse g . Ce qui les distingue, c'est la maniere dont elles exploitent cette structure :

- **ISTA/FISTA** separent f et g : un pas de gradient sur f , puis l'operateur proximal de g (le seuillage doux). C'est l'approche *full-gradient* : chaque iteration met a jour tout le vecteur x .
- La **descente par coordonnees** exploite la separabilite de $g = \lambda \|\cdot\|_1 = \sum_j \lambda |x_j|$ pour ne mettre a jour qu'une coordonnee a la fois.
- L'**ADMM** dedouble les variables (une copie pour f , une pour g) et les recoud via un multiplicateur.

- Le **Newton proximal** exploite en plus la courbure de f (la hessienne $A^\top A$), la ou ISTA/FISTA n'utilisent que le gradient.

On reconnait ISTA/FISTA comme le membre le plus « élémentaire » de cette famille : ordre 1, separation minimale, aucune structure supplementaire exploitee. Cette sobriete est a la fois leur force (generalite, simplicite, cout par iteration faible) et leur limite (convergence sous-lineaire).

7.2 Descente par coordonnees

Principe. Plutot que de bouger toutes les composantes de x ensemble, on les met a jour une par une : on fixe toutes les coordonnees sauf la j -ieme et on minimise F exactement selon x_j . Pour le LASSO, ce sous-probleme a une variable admet une solution explicite — un seuillage doux sur le residu partiel :

$$x_j \leftarrow \text{soft_threshold}\left(\frac{1}{\|a_j\|_2^2} a_j^\top (y - Ax + a_j x_j), \frac{\lambda}{\|a_j\|_2^2}\right),$$

ou a_j est la j -ieme colonne de A . On balaie les coordonnees cycliquement (ou aleatoirement) jusqu'a stabilisation.

Vitesse. Pour le LASSO, la descente par coordonnees converge a un taux asymptotiquement *lineaire*, $F(x_k) - F^* = O(\rho^k)$ avec $\rho < 1$, une fois identifie le support de la solution — bien mieux que le $O(1/k)$ d'ISTA et le $O(1/k^2)$ de FISTA dans ce regime final. C'est d'ailleurs la methode au cœur de `glmnet`, l'implementation de reference du LASSO en statistique.

Cout par iteration. Une mise a jour de coordonnee est tres bon marche ($O(n)$ si l'on maintient le residu $r = y - Ax$ de maniere incrementale). Un balayage complet des p coordonnees coute $O(np)$, comparable a une iteration d'ISTA. L'avantage decisif est l'identification automatique du support : les coordonnees nulles le restent.

Quand la preferer. Lorsque la penalite est separable (comme $\|\cdot\|_1$) et que les colonnes de A sont peu correlees ; choix par default en grande dimension statistique ($p \gg n$) avec solution tres parcimonieuse. En revanche, la methode est intrinsequement sequentielle (donc difficile a paralleliser) et perd son avantage quand g n'est pas separable.

7.3 ADMM (Alternating Direction Method of Multipliers)

Principe. On reformule le probleme en dedoublant la variable via une copie z et la contrainte $x = z$:

$$\min_{x,z} f(x) + g(z) \quad \text{s.c.} \quad x = z,$$

puis on minimise le lagrangien augmente $\mathcal{L}_\rho(x, z, u) = f(x) + g(z) + \frac{\rho}{2} \|x - z + u\|_2^2$ en alternant trois pas :

$$\begin{aligned} x_{k+1} &\leftarrow \arg \min_x f(x) + \frac{\rho}{2} \|x - z_k + u_k\|_2^2 && \text{(systeme lineaire),} \\ z_{k+1} &\leftarrow \text{prox}_{g/\rho}(x_{k+1} + u_k) && \text{(seuillage doux),} \\ u_{k+1} &\leftarrow u_k + x_{k+1} - z_{k+1} && \text{(montee de gradient duale).} \end{aligned}$$

Le pas en z est exactement le seuillage doux deja implemente pour ISTA.

Vitesse. En pratique, l'ADMM atteint une precision moderee en nettement moins d'iterations qu'ISTA (souvent quelques dizaines). Theoriquement, sa vitesse est $O(1/k)$ pour des objectifs convexes generaux, et lineaire sous hypotheses fortes ; elle depend toutefois sensiblement du parametre de penalite ρ , dont le reglage est delicat.

Cout par iteration. C'est le point faible : le pas en x exige de resoudre un systeme lineaire $(A^\top A + \rho I)x = b$. Si A est fixe, on factorise $A^\top A + \rho I$ une seule fois (Cholesky, $O(p^3)$) et chaque iteration ne coute plus que deux substitutions $O(p^2)$: l'ADMM devient alors tres competitif. Mais si ρ change ou si A est trop grande pour etre factorisee, ce pas redevient couteux. Autre nuance : contrairement a ISTA/FISTA et a la descente par coordonnees, les iterates d'ADMM ne sont pas exactement parcimonieux avant convergence (seul le bloc z l'est).

Quand le preferer. Quand le probleme se decompose naturellement (regularisations multiples, contraintes, problemes distribues), ou quand la factorisation peut etre amortie sur de nombreuses iterations. L'ADMM brille par sa modularite : on peut remplacer g par n'importe quelle fonction dont on sait calculer le prox.

7.4 Newton proximal

Principe. ISTA majore f par un modele quadratique isotrope $\frac{1}{2t} \|x - x_k\|_2^2$ (une « boule »). Le Newton proximal remplace ce modele par la vraie courbure : il utilise la hessienne $H = \nabla^2 f = A^\top A$ et resout, a chaque pas, un sous-probleme de la forme

$$x_{k+1} = \arg \min_x \nabla f(x_k)^\top (x - x_k) + \frac{1}{2} (x - x_k)^\top H (x - x_k) + g(x),$$

soit un LASSO local, resolu approximativement par un solveur interne (souvent de la descente par coordonnees). On peut aussi le voir comme une methode de Newton semi-lisse appliquee a la condition d'optimalite $0 \in \partial F(x^*)$.

Vitesse. C'est le regime le plus rapide pres de l'optimum : convergence superlineaire, voire quadratique localement ($\|x_{k+1} - x^*\| = O(\|x_k - x^*\|^2)$). La ou FISTA demande des centaines d'iterations pour gagner les derniers chiffres de precision, le Newton proximal les obtient en une poignee de pas.

Cout par iteration. Tres eleve : chaque iteration exige une information de second ordre (la hessienne ou son action) et la resolution d'un sous-probleme interne. Le pari n'est gagnant que si le faible nombre d'iterations externes compense leur cout unitaire — ce qui suppose en general une phase d'amorçage par une methode d'ordre 1 (typiquement FISTA) avant de basculer sur Newton.

Quand le preferer. Quand on vise une haute precision sur un probleme de taille moderee, ou quand f est bien conditionnee et la hessienne exploitable. A l'inverse, en tres grande dimension ou former $A^\top A$ est prohibitif, les methodes d'ordre 1 restent incontournables.

7.5 Synthèse comparative

Le tableau 1 recapitule les compromis. Aucune methode ne domine partout : le bon choix depend de la precision visee, de la taille du probleme et de la structure exploitable.

Methode	Ordre	Vitesse	Cout / iteration	Terrain de predilection
ISTA	1	$O(1/k)$	faible ($Ax, A^\top r$)	socle simple, general
FISTA	1	$O(1/k^2)$	faible (idem ISTA)	precision moyenne, par default
Coord. descent	1	lineaire (asympt.)	tres faible (1 coord.)	g separable, $p \gg n$
ADMM	1	$O(1/k)$, ρ -dep.	moyen (systeme lin.)	decomposable, distribue
Prox. Newton	2	superlin. / quadr.	eleve (hessienne + interne)	haute precision, taille moderee

Table 1: Comparaison des principales methodes pour le LASSO. « Ordre » designe l'ordre de l'information derivee utilisee. Le regime lineaire de la descente par coordonnees et le regime quadratique de Newton sont *locaux* (atteints pres de l'optimum).

Discussion des compromis. Trois arbitrages structurent ce paysage.

- *Vitesse vs. cout par iteration.* Plus une methode converge en peu d'iterations (Newton, ADMM), plus ces iterations sont cheres. ISTA/FISTA font le pari inverse : des iterations tres bon marche, quitte a en faire beaucoup. En grande dimension, ce pari est souvent le bon.
- *Generalite vs. exploitation de structure.* ISTA/FISTA ne demandent que ∇f et le prox de g — d'où leur generalite. La descente par coordonnees exige la separabilite de g ; le Newton proximal une courbure exploitable ; l'ADMM une decomposition commode. Ces hypotheses, quand elles tiennent, paient.
- *Memoire et robustesse.* ISTA/FISTA et la descente par coordonnees ont une empreinte memoire minimale. L'ADMM stocke une variable duale et idealement une factorisation ; le Newton proximal manipule de l'information de second ordre, le plus gourmand. Cote robustesse, ISTA est le plus previsible ; FISTA introduit des oscillations non monotones (cf. section 9) que des variantes *restart* corrigent ; l'ADMM est sensible a ρ ; Newton depend d'un bon amorçage.

Position d'ISTA/FISTA. En definitive, FISTA occupe un point d'equilibre remarquable : sans hypothese de structure au-dela de la separation $f + g$, sans parametre delicat a regler, avec un cout par iteration minimal, il atteint le meilleur taux possible pour une methode du premier ordre ($O(1/k^2)$, optimal au sens de Nesterov). C'est ce qui en fait le « cheval de bataille » par default, et la brique de base a partir de laquelle les autres methodes se construisent ou se comparent — d'où sa place centrale dans ce projet, les autres approches servant de points de repere pour en mesurer les forces et les limites.

8 Application : separation de sources audio

9 Experiences numeriques

10 Conclusion